Universidad de La Salle

Posgrados Ingeniería

Maestría en Inteligencia Artificial

Propuesta de proyecto

Estimación de señales rPPG y clasificación de estrés psicofisiológico mediante arquitecturas de aprendizaje profundo

Autores:

Juan Sebastian Muñoz Martinez &
Juan David Salazar Rios

Línea de Investigación:

Visión Computacional y Computación Afectiva

Fecha de entrega: 18 - septiembre - 2026

Resumen

Escribir en español el resumen con las siguientes características:
Breve y conciso: Resuma en no más de 300 palabras la propuesta de investigación. Elementos clave: Incluya el objetivo general, el problema que aborda, la metodología a utilizar y los impactos esperados en forma discursiva. Claridad: Asegúrese de que cualquier lector pueda comprender la esencia de su investigación sin necesidad de leer el documento completo.

Palabras Clave : Natural language processing, Artificial intelligence, Keyword, Keyword

Índice general

Índice de figuras **4**

Índice de cuadros **5**

1. Planteamiento del Problema **6**
Introducción 6
1.1. Análisis del Problema 7
1.2. Formulación del problema 9

2. Justificación **10**

3. Estado del Arte **12**
3.1. Categorías de Análisis 27
3.1.1. Categoría 1: Principios Ópticos y Evolución Matemática en rPPG 28
3.1.2. Categoría 2: Arquitecturas de Aprendizaje Profundo y Resiliencia Lumínica 28
3.1.3. Categoría 3: Computación Afectiva y Diagnóstico Clínico del Estrés 29
3.1.4. Categoría 4: Protocolos Clínicos, Bases de Datos y Métricas de Validación 29
3.2. Criterios 30
3.2.1. Criterios de Inclusión 30
3.2.2. Criterios de Exclusión 30
3.3. Metodología de la revisión sistemática 31
3.3.1. PRISMA 31
3.3.2. Distribución de los estudios 36
3.3.3. Distribución temporal y por arquitectura 36
3.3.4. Brechas identificadas 39
3.3.5. Hallazgos identificados 39

4. Objetivos **41**
4.1. Objetivo general 41
4.2. Objetivos específicos 41

5. Metodología **42**

6. Resultados e Impactos Potenciales **43**

7. Declaración de Derechos **44**

8. Declaración de Etica **45**

Bibliografía **49**

Índice de figuras

1. Árbol de problemas 7

1. Esquema PRISMA de selección de artículos. 34
2. Flujo de Sankey de selección de artículos. 35

Índice de cuadros

1. Algoritmos tradicionales de extracción rPPG 15
2. Algoritmos de aprendizaje profundo para la extracción rPPG 17
3. Métricas de los algoritmos de aprendizaje profundo para la extracción rPPG 20
4. Bases de datos utilizadas en investigaciones de extracción de señal rPPG 20
5. Distribución de artículos seleccionados por base de datos o fuente. . 36
6. Distribución de artículos seleccionados por año de publicación. . . . 37
7. Distribución por arquitectura de Inteligencia Artificial. 38
8. Distribución de artículos por cuartil. 38
9. Procedencia geográfica de la literatura seleccionada. 38

Capítulo 1

Planteamiento del Problema

Introducción al Problema

La salud mental se ha convertido en una de las crisis sanitarias más críticas del siglo XXI. De acuerdo con la Organización Mundial de la Salud (OMS) [1], fenómenos recientes como la pandemia global desencadenaron un aumento del 25 % en la prevalencia de la ansiedad y la depresión a nivel mundial.

El estres es capaz de afectar condiciones quimicas cerebrales mediante la hormona del cortisol, afectando capacidades de resolución de problemas y toma de deciciones incremento de la presión sanguínea y otras condiciones mentales y fisiologicas aun en estudio con un indicador relacionado a estres [2]. Desde la época pandemica, la necesidad de diagnóstico remoto aumento considerablemente emergiendo en técnicas que permitan el los procesos a distancia [3]. Ante esta urgencia, la fotopletismografía remota (rPPG) ha emergido como una tecnología prometedora para el monitoreo no invasivo de signos vitales sin necesidad de contacto fisico [4], permitiendo extraer la Variabilidad de la Frecuencia Cardíaca (HRV) a través de cámaras de video para diagnosticar el estrés de manera automatizada [5].

Sin embargo extraer está información (HRV) requiere del uso de sensores los cuales pueden ser intrusivos o no intrusivos. Para ciertos aspectos el uso de sensores intrusivos puede traer inconvenientes para las personas dado los factorees de poca portabilidad del sensor, espacios especializados, personas que tienen alguna condición que no les permite el uso prolongado de estos sistemas entre otros [6]. Es un problema que el uso de sensores no intrusivos (rPPG) ha venido a solucionar pero llevando así mismo sus propios retos. Dichos retos incluyen el debilitamiento de la señal pletismográfica por la baja reflectancia de la hemoglobina en condiciones de iluminación reducida, donde no siempre el espacio permite una iluminación

perfecta generando así una baja calidad en la información obtenida [7].

El siguiente es el diagrama del árbol de problemas (1), el cual contiene el problema principal, las causas y los efectos derivados de este:

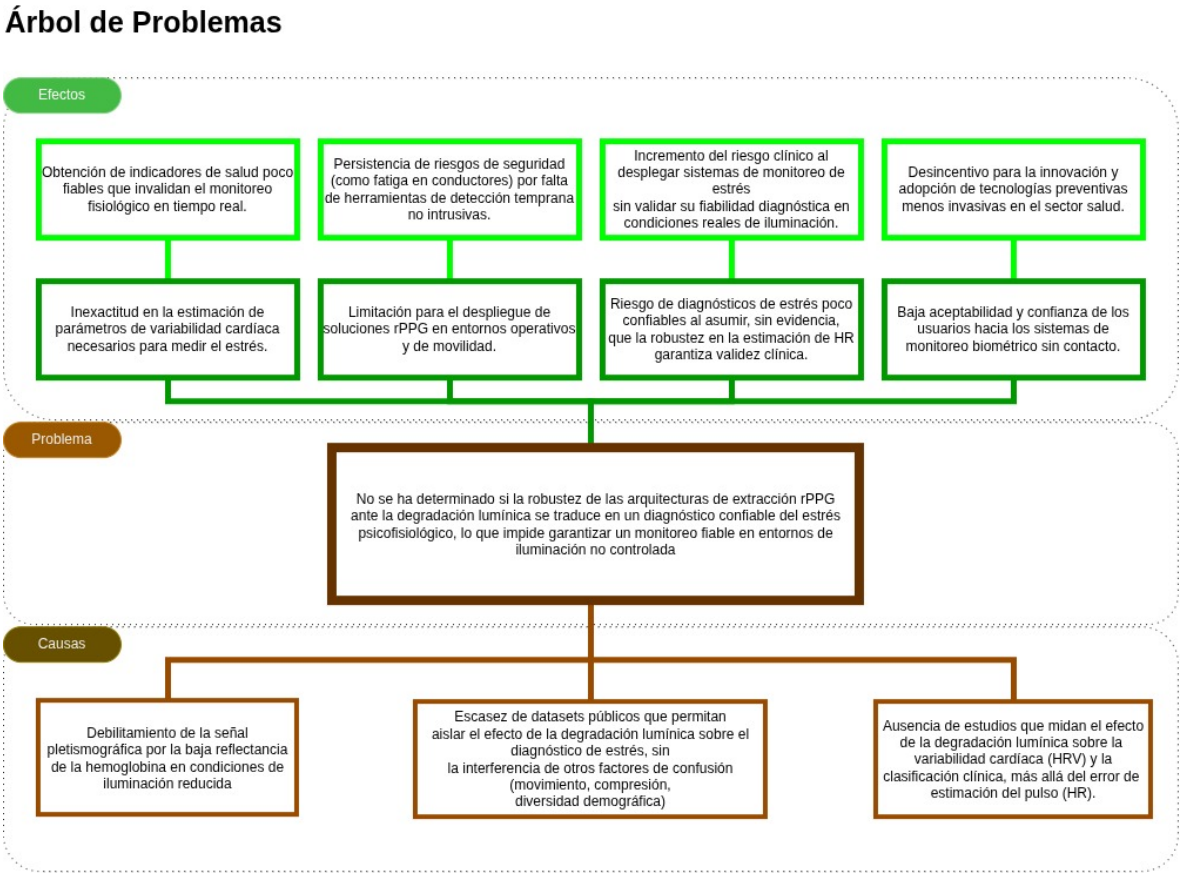


Figura 1: Árbol de problemas

1.1. Análisis del Problema

- **Debilitamiento de la señal del pulso por falta de luz en la piel** Para que las cámaras puedan medir el pulso a distancia, es necesario que la luz rebote en los vasos sanguíneos del rostro y regrese al sensor. Sin embargo, cuando la iluminación es muy baja, este rebote es casi imperceptible. En sus experimentos con iluminación controlada, Z. Yang, H. Wang y sus

colaboradores demostraron que, al bajar la luz a niveles mínimos, la señal útil proveniente de la sangre prácticamente desaparece de la piel [8]. En ese punto, la cámara deja de captar cambios de color y comienza a registrar únicamente su propio ruido electrónico, lo que genera errores críticos en las fórmulas de medición tradicionales.

- **Escasez de bases de datos relacionadas con estrés diversas y realistas para entrenar a la IA** Para que los sistemas de Inteligencia Artificial funcionen en la vida diaria, necesitan aprender de videos que incluyan a personas muy distintas bajo condiciones de luz cotidianas. No obstante, al analizar 58 bases de datos públicas, Pegueros y Rodríguez-Arce comprobaron que la gran mayoría de las investigaciones utilizan videos grabados en laboratorios con luz controlada, excluyendo a personas de diversos tonos de piel o edades [9]. Aunque algunos investigadores, como Rodrigues y Garcia, han intentado solucionar esto creando conjuntos de datos con luz natural (como rPPG-10), ellos mismos mencionan que las condiciones de población y la variedad de tonos de piel aún no son lo suficientemente amplias [9]. Además de este sesgo, Park et al. señalaron en su estudio que el proceso de validar estos videos con médicos expertos es sumamente costoso, revelando que los registros grabados en escenarios oscuros son prácticamente inexistentes en la comunidad científica [10].

- **Los modelos de extracción de señal rPPG y la condición de oscuridad**

  La extracción de señal de fotopletismografía existe hace mas de 15 años y algunos algoritmos considerados hoy en día como algoritmos tradicionales [11], como GREEN, ICA, CHROM, POS y PBV, se fundamentan en principios analíticos, modelos de reflexión óptica de la piel o técnicas de separación ciega de fuentes para aislar la variación del volumen sanguíneo a partir del promediado espacial de canales RGB en regiones de interés (ROI) faciales [12, 13, 7, 14]. Los algoritmos tradicionales presentan una vulnerabilidad crítica ante condiciones de baja iluminación, ya que la atenuación de la luz reduce la amplitud de la señal pulsátil y provoca que el ruido de cuantización del sensor domine especialmente en los canales rojo y azul, rompiendo los supuestos geométricos y de tono de piel sobre los que se construyen modelos como POS y CHROM [15, 16]

  En los últimos años, el campo de la fotopletismografía remota (rPPG) ha migrado de los algoritmos analíticos tradicionales hacia enfoques de aprendizaje profundo orientados a los datos, destacando las redes convolucionales espacio-temporales (2D/3D CNN), los Vision Transformers (ViT) y, más recientemente, los Modelos de Espacio de Estados (SSM / Mamba). A diferencia de las aproximaciones clásicas, estos modelos aprenden de forma

automática las representaciones espacio-temporales complejas que conectan las variaciones micro-cromáticas de la piel con la señal fisiológica [17, 15, 11]. Para contrarrestar la pérdida de precisión en escenarios de baja iluminación donde el ruido del sensor opaca la fluctuación sanguínea, la literatura reciente ha implementado diversas estrategias:

1. técnicas de aumento de datos por brillo para forzar la invariancia a la luminancia durante el entrenamiento [17].
2. módulos de realce de imagen y compensación de luz (como IEM o LEM) acoplados previa a la extracción [11, 18].
3. mecanismos de atención global y complejidad lineal (ViT y Mamba) para preservar la periodicidad del pulso a largo plazo [11, 15].
4. fusión multimodal (RGB e Infrarrojo Cercano - NIR) junto con paradigmas auto-supervisados [11, 19].

En el capítulo de estado del arte y metodología se abordarán con mayor profundidad el trabajo de estos algoritmos.

1.2. Formulación del problema

¿En qué medida la degradación lumínica compromete la clasificación de estrés psicofisiológico a través de la señal fisiológica rPPG?

Capítulo 2

Justificación

La fotopletismografía remota (rPPG) tiene el potencial de revolucionar el monitoreo del estrés clínico mediante el análisis no invasivo de la Variabilidad de la Frecuencia Cardíaca (HRV). Sin embargo, es de vital importancia abordar el impacto de la iluminación deficiente porque el éxito actual de estos sistemas está fuertemente sesgado hacia condiciones ideales, impidiendo su uso masivo. Al diseñar e implementar métodos de rPPG, la gran mayoría de los investigadores asumen condiciones operativas ideales, pasando por alto las enormes complejidades de desplegar estos sistemas en entornos del mundo real [4]. Z. Yang y otros confirman este sesgo metodológico al señalar que los estudios existentes exploran casi exclusivamente condiciones de laboratorio con buena iluminación, ignorando que en los espacios interiores reales la distribución de la luz es irregular y sufre variaciones frecuentes [11]. Esta dependencia de la luz perfecta evidencia un vacío crítico y demuestra la necesidad urgente de evaluar esta tecnología en escenarios realistas y cotidianos donde la iluminación fluctúa drásticamente.

El impacto de la oscuridad en la precisión del diagnóstico es un problema que no se ha logrado resolver mediante preprocesamiento visual clásico. Al evaluar arquitecturas profundas (como DeepPhys y PhysFormer) frente a videos con iluminación reducida, S. Chen, K. Wong y otros demostraron en sus métricas que aplicar filtros tradicionales de mejora de imagen (como la Ecualización de Histograma y LIME) en realidad empeora el Error Absoluto Medio (MAE) y destruye la señal rPPG [15]. Peor aún, la fiabilidad clínica se rompe precisamente cuando el paciente experimenta estrés en la oscuridad. En sus ensayos experimentales, B. Acharya y W Saakyan comprobaron a nivel práctico que cuando se evalúan los modelos ante la combinación simultánea de un ritmo cardíaco elevado (estrés) y baja iluminación (oscuridad), los errores de estimación de las redes se disparan drásticamente, demostrando que ningún método actual logra un rendimiento consistente bajo estas

dos presiones simultáneas [20].

Frente a esta desventaja óptica, es ideal encontrar una alternativa de robustez entre las arquitecturas de extracción local, como podrían ser las Redes Neuronales Convolucionales (CNN), y las de atención global, como los Vision Transformers (ViT), ya que los experimentos recientes revelan fallas estructurales en ambas topologías al enfrentar ruido [21]. Por un lado, al desarrollar sus nuevos modelos de procesamiento temporal como PhysVim, donde Z. Chang y otros, identificaron a nivel práctico que la principal limitación de las CNN por si solas es su campo receptivo local, una debilidad arquitectónica que les impide modelar dependencias espacio-temporales largas y provoca fallos sistémicos cuando la imagen presenta ruido. Aunque los ViT prometen una atención sobre todo el rostro, los experimentos de N. Nguyen, L. Nguyen y otros, demostraron su fragilidad en entornos complejos: al someter arquitecturas ViT (como EfficientPhys y ContrastPhys) a oclusión, pérdida de calidad, compresión de bits y ruido espacial sintético, sus tablas de resultados evidenciaron un colapso drástico en la precisión de los Transformers frente a la degradación visual [22].

Aportar a la resolución de este problema otorgará beneficios directos a la ingeniería biomédica al responder de qué manera afecta la iluminación deficiente a la precisión del diagnóstico de estrés. Los hallazgos establecerán una frontera medible que determine en qué punto la oscuridad contamina la señal rPPG y altera el HRV. Esto es una necesidad ya que los experimentos en laboratorio de Z. Yang, H. Wang y F. Lu demuestran que, aunque las redes profundas funcionan bien con buena luz, tienden a colapsar debido a la falta datasets con objetivos específicos pero diferente iluminación [11]. Operar con base a está degradación desde el principio evitará el efecto cascada, impidiendo que una mala señal óptica genere un falso diagnóstico psicológico.

Este proyecto de investigación busca contribuir a la exploración de sensores no invasivos, accesibles y económicos mediante el uso de tecnologías de fotopletismografía remota (rPPG). Al identificar y evaluar qué arquitecturas de aprendizaje profundo ofrecen mayor resistencia ante condiciones de iluminación baja, el estudio pretende facilitar la detección temprana del estrés, permitiendo intervenciones preventivas antes de que se manifiesten trastornos crónicos de salud mental.

Capítulo 3

Estado del Arte

El estrés ha sido considerado una problemática crítica y creciente en la sociedad moderna, afectando profundamente el bienestar mental y físico de las personas debido al ritmo de vida acelerado, las altas exigencias académicas y laborales, y la constante hiperconectividad [23]. Como un mecanismo natural de supervivencia, el estrés activa el sistema nervioso autónomo (ANS), alterando el equilibrio entre el sistema nervioso simpático (SNS) y el sistema nervioso parasimpático (PNS) [5, 24]. Sin embargo, la exposición crónica o excesiva a estas condiciones sin una regulación adecuada no solo reduce drásticamente la productividad, la concentración y la toma de decisiones, tal como se evidencia en [1, 23], sino que conduce a una desregulación prolongada del eje hipotálamo-hipofisario-adrenal [1]. La literatura médica y psicológica advierte que esta hiperactivación constante es un desencadenante principal para el desarrollo de trastornos graves de salud mental, como ansiedad generalizada y depresión, además de diversos problemas físicos y fisiológicos [1, 23, 25]. A nivel físico, el estrés crónico aumenta el riesgo de disfunciones cardiovasculares, hipertensión y debilitamiento del sistema inmunológico, e incluso se han documentado alteraciones estructurales en áreas del cerebro como la amígdala y la corteza prefrontal [1, 5, 23, 26].

Debido a estas repercusiones sistémicas, investigaciones epidemiológicas han registrado un aumento global alarmante en su prevalencia, especialmente tras la pandemia de COVID-19, convirtiendo el monitoreo y gestión del estrés en una prioridad para la salud pública y ocupacional [1]. Tradicionalmente, la cuantificación del estrés ha dependido de herramientas de autoinforme que requiere una participación consciente del individuo o por recomendación de un tercero, tales como cuestionarios estandarizados (por ejemplo, el STAI y el PSS) [5, 27]. Si bien estos instrumentos gozan de validez clínica, presentan limitaciones operativas: son susceptibles al sesgo subjetivo y no permiten una evaluación continua en tiempo real, una brecha señalada por diversos autores en [1, 5, 28].

Para superar las barreras de la subjetividad bajo un enfoque positivista, la computación afectiva se ha volcado hacia la medición objetiva utilizando datos fisiológicos. Entre las diversas métricas corporales, la Variabilidad de la Frecuencia Cardíaca (HRV) se establece como el biomarcador más robusto y fiable para monitorear las respuestas de estrés [5, 28, 29]. Dado que la HRV refleja las variaciones de tiempo entre latidos cardíacos, actúa como una ventana directa a la actividad del ANS. En este contexto, situaciones de estrés provocan que la activación simpática suprima la actividad parasimpática, lo que deriva en una reducción medible de la variabilidad, mientras que en estados de relajación, la HRV aumenta [29].

A pesar de la alta precisión de la HRV, su medición convencional requiere equipos de contacto que imponen restricciones en escenarios del mundo real: preparación lenta, dependencia de ambientes médicos y posibles irritaciones en la piel [5, 29, 30]. Es precisamente en este punto donde la necesidad de herramientas no invasivas ha impulsado la transición hacia la fotopletismografía remota (rPPG). Esta tecnología promete capturar las variaciones del volumen sanguíneo y la HRV utilizando únicamente cámaras estándar RGB sin contacto físico [5, 30], abriendo la puerta a sistemas de diagnóstico escalables en entornos cotidianos, como aulas de clase o espacios de trabajo.

La evolución de la fotopletismografía remota (rPPG) ha estado marcada por un debate constante sobre cuál es la representación matemática más robusta para extraer el pulso frente a las perturbaciones del entorno. Todo comenzó con W. Verkruysse principalmente y otros investigadores, considerados los pioneros absolutos de esta tecnología, quienes demostraron por primera vez que era posible medir el ritmo cardíaco utilizando cámaras comerciales y luz ambiental [14, 30, 31]. Ellos sentaron el estándar de la industria al descubrir que el canal verde (GREEN) de las cámaras captura la señal pulsátil más fuerte, debido a que la hemoglobina en la sangre absorbe la luz verde con mayor intensidad [11, 14].

A partir de este hito fundacional, investigadores como M. Poh. y otros, que hacen parte del referente de trabajo base de [3], [30], [14], intentaron limpiar el ruido ambiental del canal verde aplicando técnicas estadísticas de (Separación Ciega de Fuentes), específicamente el Análisis de Componentes Independientes (ICA). Es como M. Poh. en su enfoque pionero asumía que la señal del pulso y el ruido de la cámara eran fuentes completamente independientes que la matemática podía separar a ciegas, dicho de otra forma, propuso tratar el video como una mezcla de fuentes ruidosas y usar el ICA para desenredar el pulso cardiaco del ruido de la cámara, asumiendo que ambos son procesos que no se parecen en nada [3].

Aunque, en contraste con esta postura estadística, autores como De Haan y W. Wang criticaron la vulnerabilidad del método ICA ante los movimientos de la cabeza del sujeto según [3, 30]. Para solucionarlo, estos autores cambiaron el

enfoque estadístico por modelos ópticos basados en la reflexión física de la luz sobre la piel, dando origen a los algoritmos tradicionales más famosos hoy en día: CHROM (de Chromatic model creado por De Haan) y POS (de Plane orthogonal to skin creado por W. Wang) [11, 30, 18]. Ellos demostraron que, al asumir un tono de piel estandarizado y proyectar los canales RGB en planos ortogonales, se podían eliminar los reflejos especulares causados por el sudor o el movimiento, logrando una señal mucho más limpia [[3], [14], [30]] .

En la literatura de la última década se mencionan a CHROM y POS, mas específico para (CHROM desde 2013 y POS desde 2017), como los métodos de procesamiento de señales más precisos, investigaciones muy recientes han comenzado a refutar la efectividad de estos cuando se introduce la variable más crítica: la baja iluminación. Autores como L. Xi. y W. Chen, entre otros, critican los fundamentos mismos de CHROM y POS en entornos oscuros. Argumentan que estos algoritmos asumen que la iluminación sobre la piel es constante; sin embargo, advierten que en la oscuridad, esta suposición colapsa por completo porque los canales de color rojo y azul pierden casi toda su información fisiológica y son devorados por el (ruido de cuantización) de la propia cámara, la cámara traduce la luz en números digitales. En la oscuridad, los cambios causados por el pulso son tan diminutos que la cámara no puede registrarlos con precisión y se ve obligada a redondear los valores. Ese error de redondeo genera una estática que es físicamente más fuerte que el latido del corazón, terminando por ocultarlo completamente [8, 11, 16].

Curiosamente, y difiriendo de la creencia generalizada de que los modelos ópticos complejos siempre son superiores, estos autores demostraron de forma practica que en escenarios de iluminación críticamente baja, el método primitivo de Verkruysse (GREEN) y el estadístico (ICA) resultan ser más confiables que el avanzado algoritmo POS, el cual sufre una degradación extrema de su precisión al intentar mezclar canales de color vacíos [8, 11, 16].

La siguiente tabla 1 contiene una breve descripción aprovechando los analísis de otros estudios:

Cuadro 1: Algoritmos tradicionales de extracción rPPG

Algoritmo	**Autor**	**Principio / Modelo Óptico**	**Resumen del Objetivo y Mecanismo**
GREEN	Verkruysse 2008	Absorción espectral de la hemoglobina	Promedia espacialmente los píxeles del canal verde (G) en la región de interés (ROI) facial, aprovechando que esta longitud de onda presenta el mayor pico de absorción pulsátil de la sangre [8, 32, 17]
ICA / PCA Based	Lewandowska 2010	Separación Ciega de Fuentes	Descompone las trazas de 3 colores (RGB) en componentes estadísticamente independientes (ICA) o de máxima varianza (PCA) sin requerir enfoques ópticos [8, 3, 17]
CHROM	Haan & Jeanne 2013	Diferencia de crominancia y Modelo Dicromático de Shafer	Proyecta el espacio RGB temporalmente normalizado en un subespacio de crominancia para eliminar los componentes de reflexión especular (brillo) [22, 17]
PBV	Haan 2014	Firma de Volumen Sanguíneo Pulsátil (Pulse Blood Volume)	Restringe las variaciones de color a una dirección conocida en el espacio RGB, definida por la firma espectral de absorción de la hemoglobina [13, 7]
2SR	Wang 2015	Spatial Subspace Rotation	Mide la rotación temporal del subespacio formado por los píxeles de la piel entre fotogramas consecutivos, no se centra o prioriza en el tono de la piel. [33, 34]
POS	Wang 2016	Plane-Orthogonal-to-Skin	Proyecta la señal RGB temporalmente normalizada en un plano ortogonal al vector de tono de piel para cancelar las variaciones de intensidad lumínica por movimiento. [3, 17, 35, 36]

Con respecto al comportamiento de los algoritmos tradicionales frente a la iluminación deficiente, Green, al ser monocanal, evita la contaminación de otros canales ruidosos en baja iluminación, sin embargo, sufre una drástica caída de amplitud de señal y es extremadamente sensible al movimiento [8]. Según los resultados tiende a ser mas resistente que ICA y POS en cuanto a niveles de iluminación, pero en condiciones realistas los movimientos faciales son propios y naturales. Según las pruebas de [8], en baja iluminación, los canales rojo (R) y azul (B) pierden la señal pulsátil y se llenan de ruido del sensor, rompiendo la independencia lineal y degradando la separación [16]. En cuanto a POS, colapsa cuando la luz disminuye severamente, ya que el ruido de cuantización de la cámara pasa a dominar la proyección sobre el plano [8, 16]. PVB depende de un espectro de iluminación blanca constante, lo que significa que ante cambios bruscos de luz, la firma prestablecida deja de coincidir con el entorno según [13]. Según los experimentos de L. Xi y W. Chen, CHROM asume un tono de piel estandarizado y balance de blancos, cuando la luz cae y las lecturas RGB se acercan a cero, las relaciones de color se distorsionan ocasionando una degradación de la señal fotopletismografica [8]. Por último 2SR pierde precisión cuando la baja iluminación reduce el contraste del rostro, dificultando el seguimiento estable de las variaciones del ROI [33, 34].

En cuanto a la base de datos UBFC-Phys, en este estudio R. Sabour, Y. Benezeth y otros autores del estudio [36], mencionan que emplearon eleccionaron POS debido a su eficiencia computacional y velocidad de ejecución para extraer la señal rPPG y posteriormente analizar la variabilidad del ritmo cardíaco. Sin embargo como se ha mencionado anteriormente, POS resulta fuertemente afectado con el ruido de cuantización de la cámara dominando la proyección sobre el plano [8, 16].

Frente a la dificultad de las fórmulas matemáticas estáticas para lidiar con el ruido en la oscuridad, se ha estado prestando mas atención hacia modelos y arquitecturas basadas en datos, introduciendo las Redes Neuronales Convolucionales (CNN), como DeepPhys o PhysNet, capaces de aprender características espaciales de la piel directamente de los videos [15, 11, 22, 16, 37, 38, 39, 19, 40, 41, 42, 43]. Sin embargo, ante el continuo avance investigativo, la transición al Deep Learning tampoco está libre de críticas. Investigadores como Z. Yang. matizan el optimismo hacia las CNN, advirtiendo que estas redes sufren de un (sesgo inductivo local). Esto significa que las CNN se sobreajustan a las condiciones de iluminación ideales con las que fueron entrenadas en laboratorio y, en consecuencia, son menos precisas al intentar generalizar la extracción del pulso frente a variaciones lumínicas complejas o ruidos no vistos en el mundo real, esto es clave dado que podría parecer en muchos casos que tiene una clara ventaja frente a otros algoritmos [11].

Aunque los Vision Transformers surgieron como la alternativa para superar la visión local de las CNN mediante mecanismos de auto-atención global, su aplicación

pura en escenarios de baja iluminación presenta serias limitaciones. En primer lugar, los ViT carecen de sesgo inductivo espacial (*spatial inductive bias*), lo que significa que no comprenden de manera intrínseca las relaciones de vecindad de los píxeles de la piel sin un volumen masivo de datos de entrenamiento [3]. En condiciones de baja iluminación, donde la relación señal-ruido cae drásticamente debido a la escasez de iluminación, los mecanismos de atención global tienden a desestabilizarse, distribuyendo pesos de atención erróneos en regiones oscuras del fondo o ruido aleatorio del sensor en lugar de aislar la señal de rebote lúminica del rPPG.

Este debate en el estado del arte revela un vacío metodológico fundamental: la matemática óptica tradicional (como POS, CHROM y otros) falla en la oscuridad por la atenuación física de los colores, como mencionan en [11, 8, 16].

A continuación se presenta una tabla 2 con una breve descripción de los algoritmos de aprendizaje profundo aplicados a la extracción de señal fotopletismografica con los analísis extraidos de dichos estudios:

Cuadro 2: Algoritmos de aprendizaje profundo para la extracción rPPG

Algoritmo	**Autor**	**Naturaleza y Tipo de Arquitectura**	**Resumen del Objetivo y Mecanismo**
DeepPhys	Chen & McDuff 2018	CNN 2D Dual-Stream (Red convolucional de dos ramas)	Separa la entrada en dos ramas: Apariencia, que extrae características de piel/ROI y genera máscaras de atención y Movimiento que calcula la diferencia normalizada entre tramas adyacentes. [8, 12]
PhysNet	Yu et al 2019	3D-CNN Pura (Encoder-Decoder convolucional espacio-temporal)	Aplica convoluciones 3D directamente sobre secuencias de video (espacio y tiempo) para extraer la representación latente del pulso. [8]

Self-Supervised RGB-NIR ViT	Park et al 2022	Vision Transformer Multimodal de Fusión (RGB + Infrarrojo Cercano NIR)	Combina secuencias de video del espectro visible (RGB) e infrarrojo cercano (NIR) dentro de un tokenizador de video ViT con aprendizaje contrastivo auto-supervisado [10]
EfficientPhys	Liu et al. 2023	Híbrido 2D-CNN + TSM + Swin Transformer / SASN	Reemplaza las convoluciones 3D desplanzando canales a través del tiempo mediante el Temporal Shift Module (TSM) sobre capas 2D y aplicando atención Swin espacial [38]
PhysFormer / PhysFormer++	Yu et al 2022/2023	Híbrido 3D-CNN Stem + Tube Tokenizer + Temporal Difference Transformer	Extrae características locales con un Stem de 3D-CNNs, luego calcula atención global mediante Convoluciones de Diferencia Temporal (TDC) y usa una vía dual SlowFast [12]
FactorizePhys	Joshi. 2024	Híbrido 3D-CNN + Factorized Self-Attention FSAM via NMF	Utiliza Factorización de Matrices No Negativas (NMF) en el módulo FSAM sobre tensores 3D-CNN para calcular atención conjunta en espacio, tiempo y canales simultáneamente [38]
ST-Phys	Cao 2024	3D-CNN con Convoluciones Dilatadas y Módulo de Realce	Integra un Low-Light Enhancement Module (LEM), convoluciones dilatadas temporales (TDM) para ampliar el campo receptivo y atención espacial (SEM) [31].

UDA-rPPG	Wu 2024	Red con Anclaje de Dominio Geométrico-Fisiológico	Utiliza un módulo GAEM para detectar y realzar el rostro en la oscuridad (anclaje geométrico), la red LS-Phys y la pérdida (Hp-loss) enfocada en picos espectrales [14].
Phys-Vim / PhysMamba	Yan. 2024/Chang. 2025	Modelo de Espacio de Estados (SSM / Vision Mamba)	Sustituye la auto-atención cuadrática por un Escaneo Selectivo Multipat (MPSS) o dualidad estado-espacio (SSD), procesando videos largos a complejidad lineal $O(N)$ [44, 21].

En la literatura reciente de rPPG, algunos algoritmos de aprendizaje profundo han sido evaluados o diseñados explícitamente para trabajar en entornos de baja iluminación o penumbra. Por un lado, arquitecturas como DeepPhys (2D-CNN dual), PhysNet (3D-CNN) y PhysFormer (basado en Transformers) fueron puestas a prueba en conjuntos de datos oscuros (como BH-rPPG y MMPD-rPPG) mediante la adición de un módulo de realce de imagen (IEM), el cual estandariza la iluminación previa a la extracción del pulso [8].

Por otro lado, se han desarrollado arquitecturas concebidas desde su origen para resistir la oscuridad extrema. Destaca ST-Phys, un marco convolucional 3D no supervisado que integra un módulo de realce de baja luz (LEM) y convoluciones dilatadas temporales para procesar secuencias de video en niveles de iluminación de 1 a 100 lux [31]. Del mismo modo, el modelo UDA-rPPG emplea una red espacio-temporal (LS-Phys) junto con un módulo de realce geométrico (GAEM) para asegurar la detección del rostro y extraer la señal rPPG en escenarios críticos de penumbra de entre 1.0 y 3.0 lux [14].

A continuación se abordan los algoritmos de aprendizaje profundo para la extracción de rPPG y las métricas trabajadas en el desarrollo y evaluación de los algoritmos:

Cuadro 3: Métricas de los algoritmos de aprendizaje profundo para la extracción rPPG

Algoritmo	**Métricas de evaluación**	**Resultados**	**Detalles de evaluación**
PhysNet	**RMSE** y **R** (Correlación de Pearson)	RMSE: (1.812 BPM), R: 0.992	Compararón contra métodos tradiconales como POS y CHROM

Validación y Bases de Datos: El Reto de la Calidad frente a la Corrección de Imagen

En la siguiente tabla 4 se muestran las principales bases de datos de video mas usadas y empleadas por excelencia en la mayoría de investigaciones relacionadas con extracción de señal fotopletismografica mencionadas en algunas investigaciones y sus detalles:

Cuadro 4: Bases de datos utilizadas en investigaciones de extracción de señal rPPG

Base de Datos	**Autor**	**Condicioones de iluminación**	**Participantes, objetivo y sensores**
PURE	Stricker. 2014	Luz natural a través de ventana (con variaciones progresivas por nubes)	10 sujetos (60 videos de 1 min a 30 fps) con sensor Oxímetro de pulso CMS50E (BVP y SpO_2 a 60 Hz) para medir la robustez de algoritmos rPPG ante movimientos de cabeza controlados. [21, 45]
COHFACE	Heusch. 2016	Dos condiciones: iluminación natural e iluminación de estudio	40 sujetos (160 videos comprimidos en MPEG-4 a 20 fps). Oxímetro de pulso y cinturón respiratorio, creado para evaluar la extracción de rPPG en videos sometidos a alta compresión de video (256 Hz) [32, 3]

VIPL-HR	VIPL-HR. 2018/2019	Luz brillante, tenue/oscura y luz natural	107 sujetos, 2,378 videos visibles (VIS) y 752 cerca del infrarrojo (NIR) con 3 cámaras. Oxímetro CONTEC CMS60C, para la evaluación no restringida de frecuencia cardíaca a gran escala integrando movimiento y variaciones de luz [8, 10]
UBFC-rPPG	Bobbia. 2019	Luz artificial de estudio y luz ambiental de laboratorio	42 sujetos, 42 videos a 30 fps (640×480). Oxímetro de pulso transmisivo CMS50E (BVP) para evaluar la extracción de la señal rPPG y frecuencia cardíaca en un entorno estático de laboratorio con tareas matemáticas de tiempo [8, 11, 32]
BH-rPPG	Yang. 2021	3 niveles de luz controlados: baja (8 lux), media (42.4 lux) y alta (104 lux) con luz no uniforme	35 participantes, 105 videos (640×480 a 20–30 fps). Oxímetro de pulso CONTEC CMS50E para evaluar el impacto de variaciones severas de iluminancia sobre la estimación de rPPG [8, 11].
UBFC-Phys	Stricker. 2014	Iluminación de laboratorio uniforme y constante	56 sujetos con sensor Empatica E4 (BVP a 64 Hz, EDA, temperatura) y video 1024×1024 a 35 fps para estudiar las respuestas psicofisiológicas ante el estrés social mediante un protocolo TSST modificado (T1: reposo, T2: discurso, T3: aritmética) [36]

MMPD-rPPG	Stricker. 2014	4 escenarios de luz: LED alta, LED baja, incandescente y luz natural	33 sujetos (fototipos Fitzpatrick 3–6), 660 videos (11 h) grabados con Samsung S22 Ultra. Oxímetro HKG-07C+ para probar la viabilidad de rPPG en teléfonos móviles bajo escenarios reales multidominio [8, 42]
BUAA-MIHR / LRPD	Stricker. 2014	Rango controlado de 1.0 a 35 lux en canales visible e Infrarrojo Cercano (NIR)	BUAA: 15 sujetos (165 videos en 11 niveles de lux). LRPD: 42 sujetos (168 videos en 3, 8 y 35 lux). Oxímetro de pulso de contacto para Analizar la estimación de rPPG en escenarios de extrema baja iluminación [31, 14]
CHILL	Stricker. 2014	Dos condiciones de estudio: Brillante (830 lux) y Oscura (14 lux)	45 participantes, 180 videos con ejercicios (flexiones de pecho/sentadillas) para elevar HR (54 a 141 bpm). Biosignalplux Explorer Kit (PPG a 1000 Hz) para investigar el impacto combinado de la baja iluminación y frecuencias cardíacas elevadas [20]

El rendimiento de los modelos y arquitecturas de Aprendizaje Profundo en la extracción rPPG depende de la naturaleza de los datos utilizados para su entrenamiento y validación. La literatura reciente evidencia una división en la elección de bases de datos (datasets): aquellas diseñadas para maximizar el ruido del mundo real y aquellas estructuradas para aislar variables fisiológicas puras.

Por un lado, investigadores como J. Tang y K. Chen introdujeron bases de datos altamente desafiantes como MMPD, la cual incluye 33 sujetos bajo cuatro condiciones de iluminación extremas, tonos de piel diversos y artefactos de movimiento severo, citados en los estudios de [15, 46]. De forma similar, G. Heusch y A. Anjos desarrollaron el dataset COHFACE, el cual introduce ruido adicional al estar severamente comprimido en formato MPEG-4 [43]. Si bien estos datasets son útiles para forzar a las redes neuronales a lidiar con escenarios incontrolados, presentan

un problema metodológico para la investigación clínica: la saturación de variables (movimiento, compresión y luz simultáneamente) hace imposible cuantificar qué factor exacto está destruyendo la señal fisiológica.

Frente a la sobresaturación de ruido en bases como MMPD, investigadores enfocados en la fisiología pura han otorgado un valor grande a la familia de bases de datos UBFC (UBFC-rPPG y UBFC-Phys). T. Liu, en su estudio sobre generación de videos sintéticos, sostiene que UBFC-rPPG posee un valor superior como fuente de entrenamiento precisamente porque ofrece una calidad de video alta y carece de artefactos de movimiento u oclusión [43]. Al contar con un estándar de visual estático, bases como UBFC permiten a los investigadores aislar de manera precisa el impacto de una única variable (como la iluminación) sin los factores de confusión del movimiento facial [43]. Aún más crítico para el contexto de esta investigación es el salto hacia el dominio psicológico. R. M. Sabour y Y. Benezeth desarrollaron UBFC-Phys, una base de datos diseñada explícitamente para estudios psicofisiológicos del estrés social [36]. Y añadiendo el componente de computación afectiva a la ecuación, a diferencia de otros datasets que inducen emociones con simples videos, R. M. Sabour y Y. Benezeth estructuraron UBFC-Phys utilizando una versión modificada del Trier Social Stress Test (TSST), un protocolo clínico validado que incluye tareas de reposo, habla y aritmética mental, garantizando una inducción de estrés auténtica [5, 36]. Esta base de datos proporciona señales de Pulso de Volumen Sanguíneo (BVP) importantes para el calculo del HRV, y la Actividad Electrodérmica (EDA) sincronizadas con los videos, convirtiéndola en el entorno ideal para evaluar la clasificación del estrés una vez superado el reto de la extracción rPPG y clasificandolo como un recurso de caracter positivista al validar datos con sensores reales.

Al intentar resolver el desafío de la baja iluminación en las bases de datos, la comunidad científica se dividió en dos enfoques: alterar el video antes de que llegue a la red neuronal (pre-procesamiento) o robustecer la red neuronal misma.

Inicialmente, para el enfoque de pre-procesamiento, se intentó recurrir a métodos clásicos de visión computacional. Basándose en los fundamentos matemáticos establecidos por pioneros del procesamiento de imágenes como C. Poynton y T. Acharya, intentaron aplicar técnicas de aclarado fotograma por fotograma, como la Ecualización de Histograma (HE) y la Corrección Gamma (GC) [15]. La lógica detrás de la Corrección Gamma dictaba que, al aplicar una transformación de potencia no lineal sobre los píxeles, se podía aumentar artificialmente el brillo y el contraste de los rostros en la sombra, haciendo que el algoritmo evaluara mejor la piel.

Sin embargo, esta práctica ha sido duramente refutada por la literatura reciente enfocada específicamente en rPPG. En su investigación, S. Chen. [15] evaluaron

estos filtros clásicos y demostraron que métodos como la Corrección Gamma y la Ecualización de Histograma logran que la imagen se vea mejor para el ojo humano, pero destruyen la consistencia temporal de la señal cardíaca. De forma paralela, L. Xi y W. Chen profundizaron en este problema, argumentando que la compensación de iluminación aplicada superficialmente rompe la coherencia de la variación de píxeles entre fotogramas sucesivos.

Dado que el rPPG no busca (imágenes estéticamente bonitas) sino variaciones micro-cromáticas perfectas a lo largo del tiempo, aplicar Corrección Gamma altera artificialmente la distribución del color tanto en la dimensión espacial como temporal [11].

Los resultados de S. Chen evidenciaron que aplicar estos filtros a videos en baja iluminación provocaba ganancias de Relación Señal-Ruido (SNR) negativas y causaba que arquitecturas neuronales, como DeepPhys y rPPGNet fallaran, elevando sus márgenes de error [15]. En contraste con la idea de corrección Gama, investigadores como L. Xi coinciden en que es mucho más eficiente diseñar arquitecturas que aprendan características invariantes a la luz, en lugar de intentar arreglar los videos de prueba con filtros matemáticos estáticos que corrompen la señal fisiológica original se podría intentar realizar la operación inversa, es decir oscurecer los videos perfectos.

La limitación de los métodos matemáticos tradicionales frente a los cambios ambientales impulsó una transición hacia arquitecturas basadas en datos (Deep Learning). En la tarea de extracción del pulso (regresión), la literatura ha demostrado que los algoritmos tradicionales presentan márgenes de error para entornos clínicos. Por ejemplo, estudios comparativos señalan que métodos analíticos como POS y CHROM exhiben una Tasa de Error Medio Porcentual (MER) del 9.85 % y 9.17 % respectivamente [41]. Para superar esto, las Redes Neuronales Convolucionales (CNN) en dos y tres dimensiones lideraron los primeros avances. Arquitecturas como DeepPhys [15], basada en mecanismos de atención espacial y de movimiento, o modelos generativos como PulseGAN, lograron reducir drásticamente esta tasa de error porcentual (MER) a un notable 1.24 % bajo condiciones de laboratorio controladas [41]. Buscando superar el sesgo local de las convoluciones, se migró recientemente hacia la combinación de Redes neuronales convolucionales (CNN-3D) y los Vision Transformers (ViT). Z. Yu presentó PhysFormer, un modelo basado en auto-atención (self-attention) global que captura relaciones espacio-temporales de la señal a lo largo de todo el video [12, 30]. Esta arquitectura demostró una superioridad técnica en entornos bien iluminados. De hecho, algunas evaluaciones frente a variaciones de movimiento tienen como resultado que los ViT logran un Error Porcentual Absoluto Medio (MAPE) excepcionalmente bajo de 0.87 % (EfficientPhys) y 6.93 % (PhysFormer [Hibrido]), un resultado superior en comparación al 8.94 % obtenido por redes CNN 3D como PhysNet (Unicamente CNN-3D),

valores tomados de [38].

El análisis profundo del estado del arte revela una desconexión metodológica: por un lado, se invierten esfuerzos en evaluar cómo la iluminación afecta el porcentaje de error (MAPE/MER) en la extracción de latidos, y por otro, se diseñan potentes clasificadores de estrés (superando el 90 % de exactitud y F1-Score) asumiendo que la señal de entrada siempre será ideal [5]. Sin embargo, no existe en la literatura actual un estudio que integre y cuantifique cómo la degradación lumínica impacta las métricas clínicas finales.

La literatura explica una aparente superioridad de las CNN en escenarios ruidosos, la cual no se debe a una mejor capacidad de extracción fisiológica, sino a su (sesgo inductivo local), el cual actúa como un filtro natural contra la estática espacial de alta frecuencia generada por la oscuridad como explican Z. Chang y otros en [21]. Los Vision Transformers, al carecer de este sesgo y depender de parches de atención global, requieren cantidades masivas de datos para aprender a ignorar el ruido de cuantización de la cámara [21]. Cuando se enfrentan a luz deficiente sin un pre-procesamiento adecuado, la degradación espacial destruye los tensores de atención del ViT, elevando sus errores porcentuales a márgenes clínicamente inaceptables [21].

Nuevas Fronteras: Datos Sintéticos y Modelos Mamba (SSM)

Para resolver este estancamiento técnico, donde las CNN carecen de visión global y los ViT son computacionalmente frágiles ante el ruido lumínico, la investigación más reciente (2024-2025) ha propuesto dos grandes progresos. El primero es la inyección de datos sintéticos mediante modelos generativos para robustecer el entrenamiento no supervisado. T. Liu propuso la arquitectura SAFNet (Syn-rPPG), demostrando que alimentar a los modelos con videos donde se ha transferido artificialmente oscuridad y artefactos de movimiento obliga a la red a volverse resistente al ruido. Con esta técnica de datos sintéticos, SAFNet logró un MAE sobresaliente de 0.17 bpm en la base de datos UBFC-rPPG [43], superando incluso a los mejores enfoques supervisados.

El Segundo es el reemplazo total de los Transformers por los nuevos Modelos de Espacio de Estados (SSM), específicamente la arquitectura Mamba [21, 44]. Z. Chang introdujo Phys-Vim, un modelo que logra capturar dependencias espacio-temporales a largo plazo pero con una complejidad computacional lineal, eliminando el prohibitivo costo de atención cuadrática de los ViT [21]. Esto significa que el costo cuadrático de un ViT implica que a medida que aumenta la duración del video, el consumo de memoria y procesamiento de la red crece de forma exponencial (haciéndolos inviables para monitoreo en tiempo real), mientras que la complejidad lineal de la arquitectura Mamba permite que el esfuerzo computacional crezca

solo de forma proporcional a la duración del video, logrando el mismo nivel de percepción global pero de manera sumamente ligera y rápida [21]. En pruebas de validación cruzada (de UBFC-rPPG hacia PURE), Phys-Vim redujo el MAE en un 73.3 % frente a modelos Transformer previos como Spiking-PhysFormer, alcanzando un MAE de 0.72 bpm y un RMSE de 1.90 bpm, utilizando un 82 % menos de parámetros computacionales según los resultados consignados en [21].

De manera paralela, Z. Yan desarrolló PhysMamba, una arquitectura de vía dual que integra la dualidad de espacio de estados (SSD) con consultas de múltiples escalas (MQ) para intercambiar información en el dominio del tiempo y la frecuencia [44]. Al probarse en las condiciones de luz degradada y ruido de la base de datos MMPD, PhysMamba logró un MAE de 2.84 bpm y un RMSE de 6.41 bpm, superando ampliamente a modelos como TS-CAN (MAE de 8.97) y EfficientPhys (MAE de 12.79) [44].

Esta revisión crítica evidencia que la ciencia continua descifrando cómo equilibrar la capacidad de modelado global de la IA con la resistencia física al ruido lumínico. Queda claro que evaluar un algoritmo rPPG en condiciones ideales de laboratorio no ofrece garantías sobre su aplicabilidad clínica. La opciones alternativas comprenden entre trabajar modelos nuevos que puedan comprender mejor la degradación lumínica, profundizar mayormente el funcionamiento de las arquitecturas tradicionales o implementar características que permitan converger en la mezcla de modelos y generar resultados adaptables.

Brecha de Investigación y Posicionamiento del Proyecto

La revisión del Estado del Arte evidencia una convergencia clara de problemas metodológicos no resueltos:

1. **Vulnerabilidades arquitectónicas contrastantes:** Las arquitecturas de aprendizaje profundo exhiben debilidades teóricas opuestas ante la falta de luz. Mientras que los modelos avanzados como los Vision Transformers (ViT) corren el riesgo de amplificar el ruido espacial de la cámara al carecer de un sesgo inductivo local, las Redes Neuronales Convolucionales (CNN) clásicas sufren de campos receptivos limitados que restringen su comprensión temporal a largo plazo. El nivel exacto de resiliencia comparativa entre ambos enfoques bajo oscuridad pura sigue siendo una pregunta abierta en la literatura.

2. **Limitaciones en el pre-procesamiento:** Los intentos de solucionar la oscuridad aplicando filtros tradicionales de visión computacional sobre la imagen (como la Corrección Gamma) resultan clínicamente inviables, ya que destruyen la coherencia temporal de la señal y alteran las micro-variaciones cromáticas del pulso cardíaco.

3. **Sobresaturación en los Datasets:** Aunque existen bases de datos con iluminación variable en la literatura (como MMPD), la sobresaturación simultánea de variables (movimiento severo, compresión de video y luz) hace imposible aislar y medir el efecto puro de la oscuridad.

4. **Desconexión entre la extracción de la señal y la evaluación clínica del estrés:** Mientras que estudios recientes de visión computacional se limitan a medir la degradación por iluminación en términos de error de estimación del pulso (MAE o RMSE) [15, 22], las investigaciones enfocadas en la detección del estrés asumen condiciones lumínicas ideales para extraer la Variabilidad de la Frecuencia Cardíaca (HRV) y lograr altas métricas de clasificación [5, 28]. Como advierten J. P. Cobá Juárez Pegueros y J. Rodríguez-Arce [9], existe una necesidad crítica de evaluar los modelos de estrés en escenarios no controlados para garantizar su fiabilidad. Sin embargo, en la literatura actual no se ha cuantificado cómo el colapso inicial del rPPG frente a la oscuridad se propaga en cascada hasta destruir la precisión del diagnóstico psicológico.

En consecuencia, el presente proyecto de investigación se posiciona como una propuesta metodológica para hacer frente a esta brecha en la literatura. Aprovechando el rigor clínico y la estabilidad del protocolo de estrés psicofisiológico (TSST) proporcionado por la base de datos UBFC-Phys, esta investigación evitará la alteración de los videos mediante algoritmos sintéticos de mejora visual que puedan introducir artefactos en la señal. En su lugar, se identificará y seleccionará, a partir de la evidencia reportada en la literatura, el modelo o combinación de arquitecturas con mayor resistencia intrínseca ante una degradación lumínica controlada, evaluando su desempeño en penumbra sin recurrir a correcciones visuales previas. De este modo, el objetivo final no se limita a medir el error en la estimación del pulso (mediante métricas de regresión como MAE y RMSE), sino a demostrar en qué medida la preservación de la señal fisiológica rPPG permite sostener la fiabilidad en la clasificación binaria del estrés, evaluando su impacto directo en métricas de diagnóstico clínico como Accuracy y F1-Score.

3.1. Categorías de Análisis

La literatura seleccionada fue agrupada en cuatro categorías de análisis que representan las dimensiones críticas del presente proyecto. Estas categorías permiten tener un enfoque de entender el estrés y como se puede medir, transitar desde la física del sensor clinico hasta los datasets usualmente validados con caracter positivista.

3.1.1. Categoría 1: Principios Ópticos y Evolución Matemática en rPPG

Esta categoría establece las bases biológicas y las limitaciones de los modelos de procesamiento tradicionales. Para este pilar, se integraron estudios fundamentales y de revisión sistemática [11, 47], los cuales proporcionan la justificación sobre la interacción de la luz con la hemoglobina en el canal verde. Asimismo, se analizan los métodos de Separación Ciega de Fuentes y modelos ópticos de reflexión física [3, 11, 30]. Esta agrupación es indispensable porque demuestra teóricamente por qué los algoritmos clásicos como POS y CHROM colapsan ante la degradación lumínica.

3.1.2. Categoría 2: Arquitecturas de Aprendizaje Profundo y Resiliencia Lumínica

Aquí se evalúa la robustez computacional de la Inteligencia Artificial. Se seleccionaron las investigaciones sobre redes convolucionales (CNN), Vision Transformers (ViT), modelos hibridos y modelos de espacio de estados (Mamba) [12, 21, 42, 44], ya que definen la frontera actual del rendimiento. Complementariamente, se incluyeron documentos que aportan información sobre (alucinaciones) de latidos, ataques de presentación, sistemas de privacidad y datos sintéticos [14, 19, 33, 13, 45]. Este bloque fundamenta por qué se requiere someter a las redes a un oscurecimiento controlado.

La evaluación de la robustez de los modelos de Aprendizaje Profundo (Deep Learning) frente a la atenuación de la luz exige un marco experimental que aísle rigurosamente las variables bajo análisis. En el contexto de la computación afectiva, la base de datos UBFC-Phys se posiciona como el estándar de validación debido a su diseño metodológico positivista. A diferencia de otros conjuntos de datos enfocados en ruido descontrolado o expresiones faciales simples, UBFC-Phys proporciona registros de video de alta calidad sincronizados con sensores de contacto clínicos (como el dispositivo Empatica E4), capturando señales de Pulso de Volumen Sanguíneo (BVP) esenciales para el cálculo de la Variabilidad de la Frecuencia Cardíaca (HRV) bajo un protocolo clínicamente validado de inducción de estrés (Trier Social Stress Test - TSST) [17, 35]. La ausencia de oclusiones y movimientos severos en esta base de datos es clave, ya que permite aislar y cuantificar de manera pura el impacto de la degradación de la iluminación en la señal fisiológica, eliminando variables de confusión comunes en entornos incontrolados.

No obstante, dado que UBFC-Phys fue registrada bajo condiciones de iluminación ideales de laboratorio [17], la literatura científica menciona la alteración

artificial de estos entornos para evaluar la robustez. La modificación de los fotogramas mediante técnicas de oscurecimiento digital y la inyección de artefactos visuales constituye un enfoque metodológico validado para probar modelos rPPG en escenarios desafiantes [18]. Investigaciones lideradas por G. Cho y M. Kim [35]. demuestran que el brillo de los fotogramas debe ser manipulado matemáticamente a través de transformaciones lumínicas en los pixeles del rosto, una técnica preferible sobre los filtros de realce de brillo tradicionales (como la corrección Gamma o ecualización) que corrompen la dimensión temporal del latido y la señal de espectro verde. Para simular fielmente las limitaciones de los sensores ópticos reales en condiciones ambientales oscuras, se requiere complementar la pérdida de brillo con la inyección de ruido de cuantización (ruido Gaussiano con media cero), permitiendo recrear la estática de alta frecuencia que físicamente enmascara las micro-variaciones cromáticas de la piel [17].

3.1.3. Categoría 3: Computación Afectiva y Diagnóstico Clínico del Estrés

Dado que la extracción del pulso es un medio para alcanzar una evaluación médica, esta categoría articula el video con la salud mental. Se seleccionaron trabajos que detallan cómo las métricas de HRV se transforman en diagnósticos de estrés, fatiga y emociones [5, 23, 27, 28, 48, 49]. De igual forma, se integraron revisiones sobre conjuntos de datos abiertos [1, 9, 34], lo que permite plantear la hipótesis de que la degradación lumínica generará un error en cascada en el diagnóstico final.

3.1.4. Categoría 4: Protocolos Clínicos, Bases de Datos y Métricas de Validación

Para cuantificar el impacto de la oscuridad, se requiere un marco experimental estandarizado. Esta categoría agrupa los documentos que introducen y evalúan bases de datos clave como UBFC-Phys, MMPD, rPPG-10, CHILL y COHFACE [20, 36, 50, 51, 22, 11]. Finalmente, se incluyeron estudios sobre índices de calidad de la señal [41, 17], estableciendo las métricas de regresión (MAE, RMSE) y clasificación (Accuracy, F1-Score) con las que se validará el desempeño del sistema.

3.2. Criterios

3.2.1. Criterios de Inclusión

- **Rango Temporal:** El núcleo de la investigación se centra en documentos publicados entre enero de 2022 y abril de 2026. Se prioriza el periodo 2022-2024 para la evolución de modelos CNN y el periodo 2024-2026 para el estado del arte de Vision Transformers (ViT) y modelos emergentes. Se incluyen excepcionalmente obras seminales previas a 2022 para establecer el fundamento histórico de la rPPG.
- **Tipo de Fuente:** Artículos de revistas indexadas, actas de conferencias (como IEEE/CVF, CVPR, NeurIPS) y revisiones sistemáticas de literatura.
- **Bases de Datos e Idioma:** El proceso de búsqueda se realizó principalmente a través del sistema de recursos digitales de la Universidad de La Salle Colombia, en bases de datos de alto impacto como IEEE Xplore, ScienceDirect (Elsevier), PubMed y Scopus. Se empleó Google Scholar como herramienta de rastreo complementaria y se consultaron repositorios de pre-publicación (*arXiv*) para integrar avances de frontera correspondientes al año 2026. Se seleccionaron exclusivamente documentos en inglés, dado que este constituye gran parte del estándar para definiciones de computación afectiva.
- **Temática:** Estudios que integren de forma explícita el uso de rPPG con la detección de estrés o fatiga, análisis de robustez ante baja iluminación y comparativas de rendimiento entre arquitecturas de Deep Learning.

3.2.2. Criterios de Exclusión

- **Sensores de contacto:** Se descartan investigaciones basadas exclusivamente en dispositivos físicos adheridos al cuerpo (ECG, bandas de pecho, wearables) que no incluyan el uso de video o cámaras para la extracción de la señal.
- **Opacidad Técnica:** Quedan excluidos los artículos que reportan resultados de software comercial tipo caja negra, uso privativo, donde no se describe la arquitectura del modelo (CNN, ViT, etc.) ni los detalles del entrenamiento.
- **Calidad de la Fuente:** No se incluyen publicaciones en blogs, sitios de noticias, artículos de opinión o documentos de conferencias que no cuenten con un proceso comprobable de revisión por pares (No marcados con indicador *peer-reviewed*).

- **Inconsistencia Temática:** Se excluyen estudios de visión artificial enfocados únicamente en biometría (identidad, género, edad) o reconocimiento de expresiones faciales que no realicen extracción de pulso (HR/HRV) ni diagnóstico de estrés.
- **Restricción de Idioma:** Documentos publicados en idiomas distintos al inglés, con el fin de garantizar la precisión técnica de los términos y métricas estándarizadas en la literatura global de Inteligencia Artificial, estudio del estrés, bases de datos fisiológicas y computación afectiva.

3.3. Metodología de la revisión sistemática

3.3.1. PRISMA

Bajo las directrices de la metodología PRISMA, se ejecutó un proceso de selección de artículos para consolidar la base bibliográfica de la investigación, utilizando ecuaciones de búsqueda diseñadas para cubrir el espectro técnico del proyecto. El acceso a la literatura se realizó principalmente a través del sistema de recursos digitales de la Universidad de La Salle, consultando bases de datos indexadas como IEEE Xplore, ScienceDirect (Elsevier), PubMed y Scopus, además del motor complementario Google Scholar y el repositorio técnico arXiv. La búsqueda se organizó en cuatro pilares fundamentales, seleccionando términos específicos que permitieran identificar tanto los fundamentos físicos como las innovaciones en IA y diagnóstico clínico:

- **Pilar 1: Justificación del problema (El reto de la iluminación)**
  Justificación: Estos términos se seleccionaron para localizar estudios que analizan el comportamiento de los sensores y el ruido de cuantización cuando la señal lumínica es insuficiente para los métodos tradicionales.
  - **Palabras clave:** *Low-light rPPG, remote photoplethysmography, dark environment, darkness, low lux, illumination robustness, image enhancement, quantization noise, signal-to-noise ratio, SNR in rPPG.*
- **Pilar 2: Arquitecturas y Tecnologías de IA**
  Justificación: Se utilizaron para identificar la evolución desde las redes clásicas hasta los modelos de atención global y espacio de estados, permitiendo la comparación entre el sesgo inductivo local y la percepción global.
  - **Palabras clave:** *Deep Learning rPPG, remote photoplethysmography, CNN, ConvNet, Vision Transformers, ViT, PhysFormer, State Space*

Models, SSM, spatio-temporal attention, contactless monitoring, global attention, self-attention mechanism

- **Pilar 3: Fisiología, Comprensión Clínica del Estrés y Salud Mental**
  Justificación: Estos ítems permiten vincular la extracción técnica del pulso con la aplicación clínica, enfocándose en los biomarcadores que validan el diagnóstico de estrés y fatiga cognitiva.

  - **Palabras clave:** *Stress detection, remote photoplethysmography, Heart Rate Variability, HRV, affective computing, mental health monitoring, anxiety recognition, autonomic nervous system, ANS, cognitive load.*

- **Pilar 4: Metodología, Datasets y Validación**
  Justificación: Seleccionados para estándarizar la evaluación del proyecto mediante el uso de bases de datos públicas y métricas de error aceptadas unánimemente por la comunidad científica.

  - **Palabras clave:** *UBFC, UBFC-Phys, PURE, MAHOB-HCI, MMPD dataset, rPPG benchmarking, Mean Absolute Error, MAE, RMSE, Pearson correlation, r, F1-Score.*

Dichos términos se articularon mediante ecuaciones de búsqueda empleando operadores lógicos (AND, OR) y signos de agrupación (paréntesis). El diseño de estas cadenas de búsqueda contó con el apoyo de Inteligencia Artificial para optimizar la precisión de los resultados. Esta sintaxis permitió refinar el filtrado de información, asegurando que la recuperación de documentos fuera altamente pertinente para los objetivos específicos de la investigación.

El siguiente es un ejemplo de un prompt de búsqueda:

("remote photoplethysmography" OR "rPPG") AND ("stress detection" OR "anxiety recognition") AND ("Heart Rate Variability" OR "HRV" OR "Autonomic Nervous System")

El flujo de selección se dividió en las siguientes fases de filtrado:

1. **Identificación:** Se obtuvieron un total de **138 registros** a través del portal digital de la Universidad de La Salle y motores de búsqueda especializados.
2. **Filtrado:** Tras eliminar 22 documentos duplicados y fuentes no indexadas, la muestra se redujo a **116 registros** para la revisión inicial de títulos y resúmenes.
3. **Elegibilidad:** Se evaluaron **77 artículos** mediante lectura, descartando 39 documentos con metodologías opacas o falta de métricas comparativas.
4. **Inclusión:** Finalmente se repasaron 25 documentos mas que tras aplicar los criterios específicos de exclusión, se consolidó la base final de **52 documentos**, distribuidos en un sentido de búsqueda de balance en 13 artículos por cada pilar de investigación.

El siguiente diagrama (Esquema PRISMA de selección de artículos 1) representa el flujo de filtrado y elección de documentos:

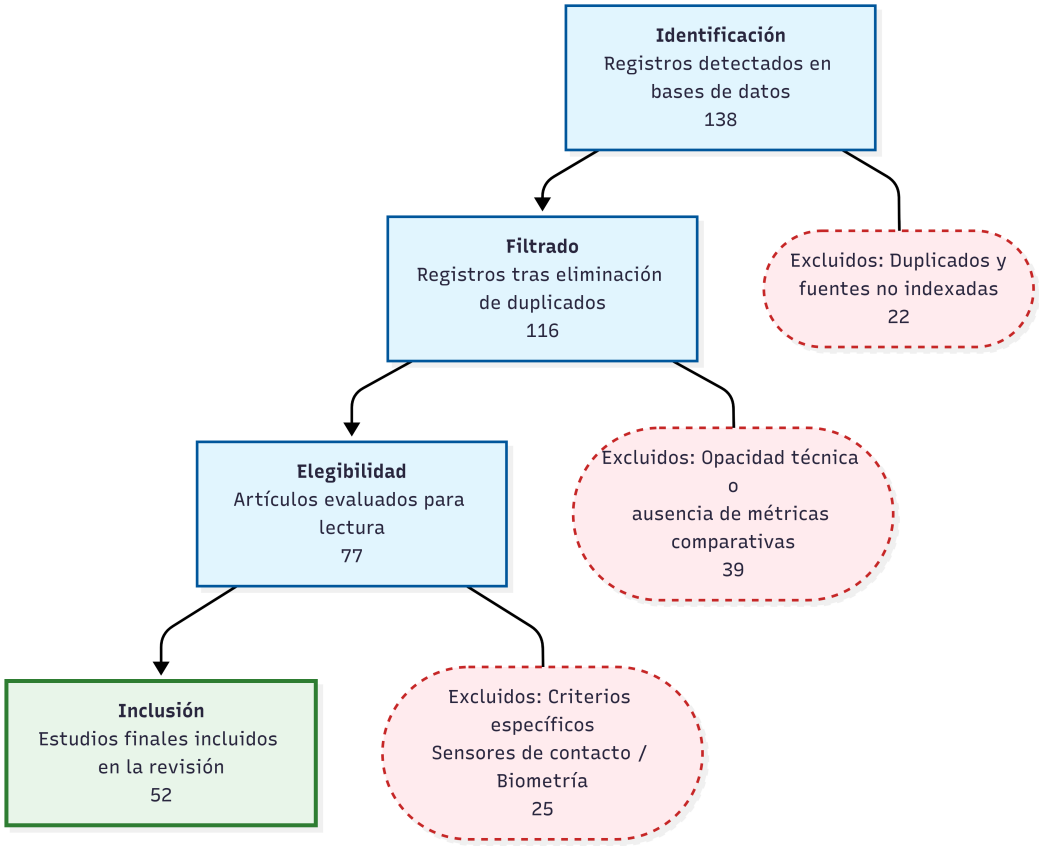


Figura 1: Esquema PRISMA de selección de artículos.

Complementariamente, se incluye un diagrama de Sankey (Flujo de Sankey de selección de artículos 2) con el fin de visualizar de manera proporcional la transición del corpus bibliográfico. A diferencia del diagrama de flujo tradicional, esta representación permite observar la magnitud de los descartes y, fundamentalmente, la distribución equilibrada de los 52 documentos finales a través de los cuatro pilares estratégicos de la investigación:

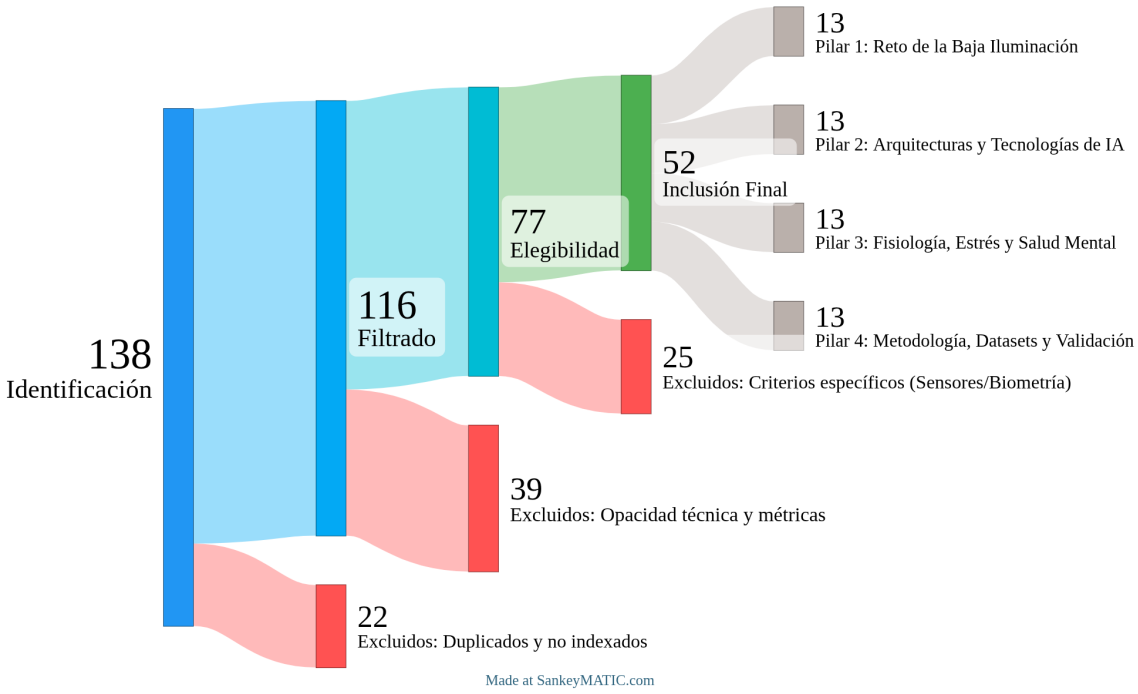


Figura 2: Flujo de Sankey de selección de artículos.

De este modo, se procede al análisis sistemático de los 52 artículos seleccionados, los cuales constituyen la base para la consolidación del estado del arte. Este proceso se orienta a la identificación de brechas tecnológicas y hallazgos convergentes que permitan fundamentar la propuesta de investigación, asegurando una síntesis crítica que nutra la matriz de variables y la posterior fase experimental.

3.3.2. Distribución de los estudios

De los 52 artículos científicos seleccionados para esta revisión, las plataformas IEEE Xplore y ScienceDirect (Elsevier) son las fuentes con mayor representación, sumando un total de 29 documentos que equivalen al 55.8 % del corpus bibliográfico. Esta concentración es consistente con la naturaleza técnica del proyecto, dado que estas bases de datos indexan las principales revistas de procesamiento de señales de video y arquitecturas de aprendizaje profundo. En la tabla (5) se puede apreciar las distribución de forma ordenada.

Cuadro 5: Distribución de artículos seleccionados por base de datos o fuente.

Base de Datos / Fuente	**Cantidad de Artículos**
IEEE Xplore (Ingenierías)	15
ScienceDirect (Elsevier)	14
MDPI (Sensors / Electronics)	10
arXiv (Literatura de frontera)	8
Otras fuentes (Nature / PubMed)	5
Total	**52**

Los estudios seleccionados presentan una ventana de publicación concentrada principalmente entre 2022 y 2026, asegurando que el análisis de los modelos Vision Transformers (ViT) y las arquitecturas Mamba representen el estado del arte más reciente en la detección de estrés mediante rPPG.

3.3.3. Distribución temporal y por arquitectura

Los estudios seleccionados para esta revisión presentan una ventana de publicación entre los años 2022 y 2026, con una tendencia creciente a partir del año 2024. Este incremento representa el 73 % del total de la muestra, lo que evidencia el auge actual de los modelos basados en atención global y su aplicación en la robustez de señales rPPG. El año 2024 destaca como el punto de mayor producción bibliográfica con 19 publicaciones, seguido muy de cerca por el año 2025 con 15 estudios indexados. La tabla (6) representa la distribución de documentos por año.

Cuadro 6: Distribución de artículos seleccionados por año de publicación.

Año de publicación	**Cantidad de Artículos**
2022	6
2023	8
2024	19
2025	15
2026	4
Total	**52**

En cuanto a la distribución por arquitectura de los 52 artículos seleccionados, un análisis detallado de sus estructuras internas revela una taxonomía más diversa que la categorización genérica tradicional. Las **Redes Convolucionales (CNN) puras** abarcan 10 publicaciones (19.2 %). No obstante, para superar las limitaciones de las convoluciones aisladas, la literatura ha explorado diversas combinaciones híbridas: 8 estudios (15.4 %) emplean **modelos híbridos de CNN con redes recurrentes (CNN + LSTM/GRU)** enfocados principalmente en el modelado temporal de variaciones fisiológicas, 10 estudios (19.2 %) corresponden a **CNNs optimizadas con módulos de atención integrada** (como TS-CAN y Peak Attention) y 5 publicaciones (9.6 %) representan **modelos híbridos de CNN 3D con Vision Transformers (CNN 3D − ViT)** como PhysFormer y TransPhys, los cuales anteponen un *Stem* convolucional para estabilizar la extracción local de la piel. Por su parte, los **Vision Transformers (ViT) puros** representan 7 investigaciones (13.5 %). Finalmente, los modelos emergentes de **Espacio de Estados (Mamba / SSM)** y los **métodos tradicionales de filtrado óptico** abarcan 6 artículos cada uno (11.5 % respectivamente). Esta caracterización detallada demuestra la evolución continua hacia arquitecturas compuestas y evidencia la diversidad de mecanismos disponibles para abordar la resiliencia en penumbra, los cuales serán analizados y contrastados en el primer objetivo específico para seleccionar el más adecuado al alcance de este proyecto. En la tabla (7) se presenta el desglose detallado de esta distribución:

Cuadro 7: Distribución por arquitectura de Inteligencia Artificial.

Arquitectura / Enfoque	**Cantidad de Artículos**
Redes Convolucionales (CNN Puras)	10
CNN + Módulos de Atención (sin Transformer)	10
Híbridos CNN + RNN / LSTM / GRU	8
Vision Transformers (ViT Puros)	7
Modelos de Espacio de Estados (Mamba / SSM)	6
Métodos Tradicionales / Filtros Ópticos	6
Híbridos CNN 3D + Vision Transformer (ViT)	5
Total	**52**

De igual forma la tabla (8) representa la distribución de artículos por cuartil, que representa el impacto de las investigaciones en este campo:

Cuadro 8: Distribución de artículos por cuartil.

Clasificación / Cuartil	**Cantidad de Artículos**
Q1	22
Q2	20
Sin categoría / Pre-prints	10
Total	**52**

Por último se presenta la tabla (9), un indicador de la distribución de investigación en este campo por paises, con un claro liderzago por parte investigadores de universidades de China

Cuadro 9: Procedencia geográfica de la literatura seleccionada.

País de origen	**Cantidad de Artículos**
China / Finlandia	25
Corea del Sur	11
Estados Unidos	6
Europa (Francia, otros)	5
Otros (India, etc.)	5
Total	**52**

3.3.4. Brechas identificadas

El análisis del corpus bibliográfico revela algunas brechas relevantes que representan retos pero así mismo oportunidades para la investigación:

- **Desconexión entre robustez en la estimación del pulso y fiabilidad del diagnóstico de estrés:** Existen múltiples arquitecturas diseñadas específicamente para mitigar el efecto de la baja iluminación en la extracción del pulso (HR), como DeepPhys, PhysNet, PhysFormer y ST-Phys, entre otras. Sin embargo, ninguna reporta el impacto de esta degradación sobre la Variabilidad de la Frecuencia Cardíaca (HRV) ni sobre tareas de clasificación clínica del estrés, solo en el ritmo cardiaco. Se desconoce en qué punto un modelo robusto en la estimación de HR deja de sostener un diagnóstico confiable de estrés [1, 27, 9, 20, 50, 32].
- **Uso de videos oscurecidos por software:** Como casi no existen videos de personas grabadas en la oscuridad total, los investigadores sugieren oscurecer los videos normales usando programas. Todavía falta comprobar si este método de oscurecer videos artificialmente afecta de la misma manera a todos los tipos de modelos de IA [22, 41, 43, 51, 52].
- **Falta de comparación bajo un protocolo clínico unificado:** Aunque existen múltiples estrategias específicas redes convolucionales puras, híbridas CNN-ViT, modelos de espacio de estados para mitigar el ruido lumínico, cada una ha sido validada en datasets distintos y bajo condiciones de degradación diversas (iluminación física vs. digital, distintos niveles de atenuación). Esto impide determinar, bajo un mismo protocolo clínico como UBFC-Phys y su protocolo TSST, cuál preserva mejor la fiabilidad del diagnóstico de estrés. [3, 37, 22, 38, 12, 21, 44].

3.3.5. Hallazgos identificados

Así mismo se revelan algunos hallazgos relevantes que acompañan el proceso de investigación. Su identificación es crucial y se definen posibles rutas en un mapa de trabajo investigativo:

- **Fallas en los filtros de imagen:** Los filtros para aclarar videos (como el ajuste de brillo o contraste) crean distorsiones de color que dañan la señal del pulso. Por esto, la capacidad de ver en la oscuridad debe ser una característica interna de la IA, y no depender de arreglos previos en el video [11, 8, 16].
- **Uso de una base de datos estándar:** La base de datos *UBFC-Phys* es la más recomendada para este estudio. Al usar una prueba estándar (TSST)

para estresar a las personas, ayuda a que el movimiento del cuerpo no afecte los datos finales y los resultados sean más reales [1, 36, 9].

- **Punto de comparación (Línea base):** Con buena luz, los modelos de IA clásicos logran una precisión mayor al 85 % usando los datos del corazón [23, 5, 28].
- **Mecanismos de extracción y focalización de características:** Se evidenció que los enfoques convolucionales emplean con frecuencia módulos de diferenciación temporal (como la diferencia de fotogramas adyacentes) para suprimir la luminancia estacionaria y aislar las variaciones cromáticas subyacentes. Por su parte, la integración de mecanismos de atención tanto en redes convolucionales como en modelos basados en Transformers permite ponderar dinámicamente las regiones faciales con mayor perfused vascular (como mejillas y frente), optimizando la selección de la región de interés (ROI) y mitigando el impacto del ruido ambiental en la señal fisiológica [38, 40, 46, 35].

Capítulo 4

Objetivos

4.1. Objetivo general

Desarrollar un modelo que estime señales rPPG para que clasifique el estrés psicofisiológico en dos categorías a partir de video, evaluando su comportamiento ante condiciones sintéticas y controladas de degradación lumínica.

4.2. Objetivos específicos

- Seleccionar la técnica para extraer señales rPPG identificadas en la revisión de literatura frente a cambios en las condiciones de iluminación.
- Preparar un conjunto de datos a partir de videos extrayendo la región facial de interés y generando tres condiciones de iluminación.
- Construir el modelo de estimación de rPPG y clasificación del estrés psicofisiológico integrando los métodos y técnicas seleccionadas en la revisión de literatura y entrenándolo con el conjunto de datos preparado.
- Evaluar el desempeño del modelo mediante métricas de error para la estimación de la señal rPPG y métricas de precisión para la clasificación del estrés.

Capítulo 5

Metodología

Enfoque metodológico: Describa el enfoque general (cuantitativo, cualitativo, mixto) que utilizará.

Técnicas y procedimientos: Detalle las técnicas y procedimientos específicos que empleará para recoger y analizar los datos, incluya un diseño detallado de experimentos y pruebas de laboratorio a realizar.

Cronograma: Incluya un cronograma de actividades que muestre las etapas de la investigación.

Capítulo 6

Resultados e Impactos Potenciales

Explique los resultados que espera obtener de su investigación. Describa cómo estos resultados contribuirán al conocimiento o la práctica en su campo de estudio.

Describa el impacto que su investigación podría tener en la academia y la ciencia. Explique los posibles beneficios sociales y económicos de su investigación. Considere el impacto ambiental y la sostenibilidad de los resultados de su investigación.

Capítulo 7

Declaración de Derechos

Defina cómo se gestionarán los derechos de propiedad intelectual derivados de su investigación. Establezca los acuerdos de derechos y autoría en caso de colaboraciones con otros investigadores o instituciones. Asegúrese de que los términos de propiedad y uso de los resultados sean claros y transparentes.

Capítulo 8

Declaración de Etica

Deberá definir como impacta en los principios éticos el proyecto a realizar. Colocar lo visto en el curso de ética.

Modalidad de Grado

Seleccionar una

- Desarrollo de un proyecto investigativo disciplinar o multidisciplinar Esta modalidad de grado se refiere al desarrollo de proyectos de investigación que respondan a problemáticas concretas en diferentes contextos socioeconómicos y culturales. Se fundamenta en la aplicación de los avances de la ingeniería en diferentes áreas de énfasis para abordar problemáticas sociales de los contextos local, regional, nacional o internacional. Cuando el trabajo de grado sea en grupo, se permitirá un máximo de tres estudiantes. La dirección del programa designará un tutor que acompañe el proceso desde su formulación hasta la sustentación del informe final.

Producto escrito Esta modalidad de grado incluye la entrega de un informe escrito y su correspondiente sustentación. La valoración del informe debe tener en cuenta la coherencia y el rigor metodológico; la fundamentación teórica; la presentación y análisis de los resultados; las conclusiones y recomendaciones, y la correspondencia entre las necesidades del entorno, la naturaleza del proyecto y los resultados obtenidos.

- Producción intelectual relevante La relevancia de esta modalidad de grado depende de la calidad de la producción académica. En tal sentido, la naturaleza del producto debe cumplir con claros estándares de calidad, innovación, sistematicidad y correspondencia respecto a los propósitos formativos del programa al que se vincula el estudiante. De esa forma, se asume como producción intelectual relevante la publicación de un libro, capítulo de libro o artículo publicado en una revista, institucional o externa, especializada en los campos de conocimiento inherentes

al programa del estudiante Estas publicaciones deben contar con los respectivos registros de isbn o issn, dependiendo de si es un libro o parte de una publicación periódica, bien sea en formato digital o impreso. Dentro de esta modalidad también se contemplan las revistas indexadas alojadas en plataformas científicas avaladas a escala internacional.

Asimismo, se contempla como producción intelectual relevante el diseño de un software relacionado con el campo de formación; el diseño o la modelación original de algún tipo de sistema o subsistema ligado con el programa de estudio y validado por un experto; la construcción y validación de nuevos protocolos, y la formulación o realización de proyectos de emprendimiento. La dirección del programa de Maestría en Ingeniería designará un tutor que acompañe el proceso, con el objetivo de garantizar el desarrollo de las competencias investigativas requeridas y la calidad del producto final.

Producto escrito Asumiendo que la producción intelectual generada por el estudiante no es un simple requisito, en el caso de la publicación de un libro, capítulo de libro o artículo, no será necesario un informe escrito adicional. Para los otros tipos de producto contemplados en esta modalidad, se deberá entregar un informe que contenga los propósitos, procedimientos y resultados que condujeron a la elaboración del producto entregado. Nota: debe tener la afiliación de la Universidad de La Salle.

- Elaboración de una propuesta de política pública en el campo del conocimiento Se refiere a la posibilidad de construir una propuesta de política pública o de participar en la construcción de esta a partir de una disciplina o campo interdisciplinar inherente al programa de formación del estudiante. En todo caso, la propuesta o generación de política pública debe plantear alternativas en uno o varios ámbitos del desarrollo local, regional o nacional. Esta política pública debe orientarse por principios de desarrollo social asociados al Estado, no a intereses particulares. Debe explicitar los intereses públicos a los que sirve y precisar por qué son una alternativa al modelo o a los modelos existentes. La propuesta debe ser valorada por un experto en política pública que conozca el campo. Una vez avalada por este, el estudiante o grupo de estudiantes la presentará de manera formal ante las instancias gubernamentales pertinentes. La dirección del programa designará un tutor que acompañe el pro- ceso, para garantizar el desarrollo de las competencias investigativas requeridas y la calidad del producto final.

Producto escrito Dadas las características de esta modalidad, según el caso, el

producto escrito consistirá en la propuesta en sí misma, acompañada por su soporte de radicación ante la entidad correspondiente, o en el documento de la política pública con los soportes que demuestren su ejecución. En cuanto a su estructura, contará con cada uno de los elementos constitutivos de una política pública según el campo correspondiente. Un experto en política pública deberá valorar este producto una vez el tutor de la modalidad emita el aval correspondiente.

Bibliografía

[1] C. Chatzaki and M. Tsiknakis, "An overview of stress analysis based on physiological signals: Systematic review of open datasets and current trends," *Sensors*, 2025. [Online]. Available: https://www.mdpi.com/1424-8220/25/23/7108

[2] S. Gopi and N. Dehbozorgi, "Serenepulse: A web app pipeline for real-time physiological monitoring using rppg and openai llms," in *ASEE Annual Conference and Exposition*, 2024. [Online]. Available: https://peer.asee.org/47963

[3] R.-X. Wang, H.-M. Sun, R.-R. Hao, A. Pan, and R.-S. Jia, "Transphys: Transformer-based unsupervised contrastive learning for remote heart rate measurement," *Biomedical Signal Processing and Control*, 2023. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1746809423004913

[4] C. Álvarez Casado, S. Sharifipour, M. L. Cañellas, N. Nguyen, L. Nguyen, and M. B. López, "Design, implementation and evaluation of a real-time rppg acquisition system," in *Nordic Conf. Digital Health and Wireless Solutions*, 2024. [Online]. Available: https://arxiv.org/abs/2508.18787

[5] L. Fontes, P. Machado, D. Vinkemeier, S. Yahaya, J. J. Bird, and I. K. Ihianle, "Enhancing stress detection: A comprehensive approach through rppg analysis and deep learning techniques," *Sensors*, 2024. [Online]. Available: https://www.mdpi.com/1424-8220/24/4/1096

[6] J. W. Chin, P. H. D. Chan, S. Chen, C. H. Cheng, R. H. Y. So, E. Chow, B. S. P. Fok, and K. L. Wong, "Clinical validation of rppg-enabled contactless pulse rate monitoring software," *Bioengineering*, 2026. [Online]. Available: https://www.mdpi.com/2306-5354/13/2/246

[7] K. Yang, N. Long, K. Cao, B. Huang, Z. Chen, Y. Zeng, T. Tan, C. Shan, J. Jiang, and Y. Sun, "Self-adaptive illumination enhancement for neonatal remote physiological measurement in nicus," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2025. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/11145169

[8] Z. Yang, H. Wang, and F. Lu, "Image enhancement for remote photoplethysmography in a low-light environment," *arXiv preprint arXiv:2107.13193*, 2023. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/9320298

[9] Rodríguez-Arce, Jorge, Morales-Fajardo, H. Manuel *et al.*, "Physiological datasets in stress and anxiety research: A systematic review," *Biomedical Signal Processing and Control*, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1746809425004392

[10] S. Park, B.-K. Kim, and S.-Y. Dong, "Self-supervised rgb-nir fusion video vision transformer framework for rppg estimation," *ieeexplore*, 2022. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/9931758

[11] Z. Yang, H. Wang, and F. Lu, "Assessment of deep learning-based heart rate estimation using remote photoplethysmography under different illuminations," *ieeexplore*, 2022. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/9913818

[12] Z. Yu, Y. Shen, J. Shi, H. Zhao, Y. Cui, J. Zhang, P. Torr, and G. Zhao, "Physformer++: Facial video-based physiological measurement with slowfast temporal difference transformer," *International Journal of Computer Vision*, 2023. [Online]. Available: https://link.springer.com/article/10.1007/s11263-023-01758-1

[13] M. Xu, Z. Liu, and X. He, "Ivrr-ppg: An illumination variation robust remote-ppg algorithm for monitoring heart rate of drivers," *IEEE Transactions on Instrumentation and Measurement*, 2023. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/10113355

[14] J. Wu, X. Cheng, and Z. Sun, "Uda-rppg: Unsupervised geometric-physiological domain anchoring for low-light rppg measurement," *IEEE Transactions on Instrumentation and Measurement*, 2026. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/11176934

[15] S. Chen, K. L. Wong, T. T. Chan, Y. Wang, R. H. Y. So, and J. W. Chin, "An image enhancement based method for improving rppg extraction

under low-light illumination," *Biomedical Signal Processing and Control*, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1746809424010218

[16] L. Xi, X. Wu, W. Chen, J. Wang, and C. Zhao, "Weighted combination and singular spectrum analysis based remote photoplethysmography pulse extraction in low-light environments," *Medical Engineering and Physics*, 2022. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1350453322000716

[17] U. Debnath and S. Kim, "Advanced signal-processing framework for remote photoplethysmography-based heart rate measurement," *PLoS ONE*, 2026. [Online]. Available: https://doi.org/10.1371/journal.pone.0340097

[18] D.-Y. Kim, S.-Y. Cho, K. Lee, and C.-B. Sohn, "A study of projection-based attentive spatial-temporal map for remote photoplethysmography measurement," *Bioengineering*, 2022. [Online]. Available: https://www.mdpi.com/2306-5354/9/11/638

[19] S. Jeremy, V. Nathan, S. Benjamin, N. Lu, F. Patrick, and C. Adam, "Hallucinated heartbeats: Anomaly-aware remote pulse estimation," *arXiv arXiv:2303.06452*, 2023. [Online]. Available: https://arxiv.org/abs/2303.06452

[20] B. Acharya, W. Saakyan, B. Hammer, and H. Drimalla, "The reliability of remote photoplethysmography under low illumination and elevated heart rates," *npj Digital Medicine*, 2025. [Online]. Available: https://www.nature.com/articles/s41746-025-02192-y

[21] Z. Chang, H. Wang, Y. Han, J. Lv, and B. Li, "Phys-vim: State space model for remote physiological measurement," *Neurocomputing*, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0925231225020776

[22] N. Nguyen, L. Nguyen, H. Li, M. B. López, and C. Álvarez Casado, "Evaluation of video-based rppg in challenging environments: Artifact mitigation and network resilience," *Computers in Biology and Medicine*, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0010482524009582

[23] M. Mouadili, En-Naimi, and M. E.M. Kouissi, "Advancing stress detection and health monitoring with deep learning approaches," *Computer Science and Mathematics Forum*, 2025. [Online]. Available: https://www.mdpi.com/2813-0324/10/1/10

[24] X. Tao, L. Su, Z. Rao, Y. Li, D. Wu, X. Ji, and J. Liu, "Facial video-based non-contact emotion recognition: A multi-view features expression and fusion method," *Biomedical Signal Processing and Control*, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1746809424006669

[25] G. Singh, O. C. Phukan, and R. Kumar, "Stress recognition with multi-modal sensing using bootstrapped ensemble deep learning model," *Expert Systems*, 2023. [Online]. Available: https://doi.org/10.1111/exsy.13239

[26] M. Khomidov, D. Lee, C.-H. Kim, and J.-H. Lee, "The real-time image sequences-based stress assessment vision system for mental health," *Electronics*, 2024. [Online]. Available: https://www.mdpi.com/2079-9292/13/11/2180

[27] M.-F. H. Manuel, R.-A. Jorge, G.-C. Alejandro, V. J. Caballero, R.-L. J. Javier, A.-C. E. Alonso, L.-R. C. Ivette, and V.-G. A. H., "Towards a non-contact method for identifying stress using remote photoplethysmography in academic environments," *Sensors*, 2022. [Online]. Available: https://www.mdpi.com/1424-8220/22/10/3780

[28] M. Bahameish, T. Stockman, and J. R. Carrion, "Strategies for reliable stress recognition: A machine learning approach using heart rate variability features," *Sensors*, 2024. [Online]. Available: https://www.mdpi.com/1424-8220/24/10/3210

[29] A. Brown, J. Tulkens, M. Mattelin, T. Sanglet, and B. Dhuyvetters, "Remote photoplethysmography for health assessment: a review informed by intelliprove technology," *Frontiers in Digital Health*, vol. 7, 2026. [Online]. Available: https://www.frontiersin.org/journals/digital-health/articles/10.3389/fdgth.2025.1667423/full

[30] Z. Yue, S. Ding, and H. Ma, "Facial video-based non-contact stress recognition utilizing multi-task learning with peak attention," *IEEE Journal of Biomedical and Health Informatics*, 2024. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/10553390

[31] M. Cao, X. Cheng, X. Liu, and Y. Jiang, "St-phys: Unsupervised spatio-temporal contrastive remote physiological measurement," *IEEE Transactions on Instrumentation and Measurement*, 2024. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/10530325

[32] X. Zhan, C. Zhou, Y. Wei, F.-M. Dahlweid, H. Sun, C. Wang, B. Xie, and X. Zhang, "Estimating heart rate variability parameters in long-term rppg signals using spatiotemporal attention mechanisms,"

Biomedical Signal Processing and Control, 2026. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1746809425009188

[33] D. Gupta and A. Etemad, "Privacy-preserving remote heart rate estimation from facial videos," *arXiv preprint arXiv:2306.01141*, 2023. [Online]. Available: https://arxiv.org/abs/2306.01141

[34] O. Ismoil, W. K. Long, C. J. Wei, G. Raghav, C. T. Tai, and S. R. H. Y., "Robust heart rate variability measurement from facial videos," *Bioengineering*, 2023. [Online]. Available: https://www.mdpi.com/2306-5354/10/7/851

[35] G. Cho, M.-J. Kim, and C. W. Ahn, "A dual-branch spatio-temporal feature differencing method for robust rppg estimation," *Mathematics*, 2025. [Online]. Available: https://www.mdpi.com/2227-7390/13/23/3830

[36] R. M. Sabour, Y. Benezeth, P. D. Oliveira, J. Chappé, and F. Yang, "Ubfc-phys: A multimodal database for psychophysiological studies of social stress," *IEEE Transactions on Affective Computing*, vol. 14, no. 1, 2023. [Online]. Available: https://ieeexplore.ieee.org/document/9476001

[37] X. G., Y. S., P. Y., D. H., W. X., W. K., L. Y., and W. F., "An effective cross-scenario remote heart rate estimation network based on global-local information and video transformer," *Multimedia Systems*, 2024. [Online]. Available: https://doi-org.hemeroteca.lasalle.edu.co/10.1007/s13246-024-01401-4

[38] J. Joshi, S. S. Agaian, and Y. Cho, "Factorizephys: Matrix factorization for multidimensional attention in remote physiological sensing," *arXiv preprint arXiv:2405.21060*, 2024. [Online]. Available: https://arxiv.org/abs/2405.21060

[39] J. Zhuang, Y. Chen, Y. Zhang, and X. Zheng, "Fastbvp-net: a lightweight pulse extraction network for measuring heart rhythm via facial videos," *arXiv preprint arXiv:2206.12558*, 2022. [Online]. Available: https://arxiv.org/abs/2206.12558

[40] Q. Xue, X. Zhang, Y. Zhang, A. Hekmatmanesh, H. Wu, Y. Song, and Y. Cheng, "Non-contact rppg-based human status assessment via a spatial-temporal attention feature fusion network with anti-aliasing," *Computers in Industry*, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0166361524001556

[41] R. Ma and C. Chen, "Rf-bayesphysnet: A bayesian rppg uncertainty estimation method for complex scenarios," *arXiv preprint arXiv:2504.03915*, 2025. [Online]. Available: https://arxiv.org/abs/2504.03915

[42] K. Cen, C.-H. Fu, and H. Hong, "Robust and generalizable heart rate estimation via deep learning for remote photoplethysmography in complex scenarios," *arXiv preprint arXiv:2507.07795*, 2025. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/11347742

[43] T. Liu, H. Xiao, Y. Sun, K. Zuo, Q. Zhang, Z. Li, and F. Zhou, "Syn-rppg: Improving unsupervised remote photoplethysmography extraction with synthesized videos using generative models," *Engineering Applications of Artificial Intelligence*, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0952197625005044

[44] Z. Yan, Y. Zhong, H. Xu, W. Zhang, S. Yi, L. Shu, and W. Kang, "Physmamba: Synergistic state space duality model for remote physiological measurement," in *arXiv preprint arXiv:2408.01077*, 2025. [Online]. Available: https://arxiv.org/abs/2408.01077

[45] D. Qiao, A. H. Ayesha, F. Zulkernine, N. Jaffar, and R. Masroor, "Revise: Remote vital signs measurement using smartphone camera," *IEEE Access*, 2022. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/9989351

[46] P. Zhao, Q. Sun, X. Tian, Y. Yang, S. Tao, J. Cheng, and J. Chen, "Toward motion robustness: A masked attention regularization framework in remote photoplethysmography," *arXiv preprint arXiv:2407.06653*, 2024. [Online]. Available: https://arxiv.org/abs/2407.06653

[47] J. Wang, C. Shan, L. Liu, and Z. Hou, "Camera-based physiological measurement: Recent advances and future prospects," *Neurocomputing*, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0925231224000535

[48] K. Kakhi, S. K. Jagatheesaperumal, A. Khosravi, R. Alizadehsani, and U. R. Acharya, "Fatigue monitoring using wearables and ai: Trends, challenges, and future opportunities," *Computers in Biology and Medicine*, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0010482525008121

[49] C.-F. Hsu, S. P. K. Mudiyanselage, R. Agustina, and M.-F. Lin, "Basic emotion detection accuracy using artificial intelligence approaches: A systematic review," *Applied Soft Computing*, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1568494625001784

[50] G. Rodrigues and N. M. Garcia, "Evaluating remote photoplethysmography: A 10-minute video dataset in uncontrolled lighting," *Data in Brief*,

2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2352340925006122

[51] Y. Benezeth, D. Krishnamoorthy, D. J. B. Monsalve, K. Nakamura, R. Gomez, and J. Mitéran, "Video-based heart rate estimation from challenging scenarios using synthetic video generation," *Biomedical Signal Processing and Control*, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1746809424006566

[52] X. Liu, Y. Zhang, Z. Yu, H. Lu, H. Yue, and J. Yang, "rppg-mae: Self-supervised pre-training with masked autoencoders for remote physiological measurement," *IEEE Transactions on Multimedia*, 2023. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/10430462